

ACP cheat sheet

On considère la matrice X du nuage de point avec n individus et p variables, donc $X \in M^{n \times p}$.

Le but d'une ACP est de déterminer de nouveaux axes $a_i \in \mathbb{R}^p$ (souvent 3 ou 4) tels que l'inertie (ou la variance) de la projection du nuage de point sur ces nouveaux axes soient maximale.

On pourra alors écrire X en fonction des coordonnées des individus dans ces nouveaux axes. On nommera alors les nouvelles variables composantes principales, les axes étant eux appelés axes principaux.

Transformation de l'échantillon:

Deux possibilités : Centrer la matrice ou la centrer-réduire. On notera $\bar{X} = (\bar{X}_1, \dots, \bar{X}_p)$ la matrice X centrée et \hat{X} la matrice X centrée-réduite (toujours en colonne). On utilisera la notation M pour désigner \bar{X} ou \hat{X} suivant le cas choisi. Si les variables ne sont pas à la même échelle (par ex des grammes avec des distances en mètre), il faut obligatoirement réduire le nuage de point.

Projection

Soit $u \in \mathbb{R}^p$ un vecteur de norme 1. La projection de l'échantillon M sur u dans la base u s'écrit :

$$\pi_u(M) = M \cdot u \quad (1)$$

Preuve :

Prenons m_1 , le premier individu centrée réduit de M . m_1 peut s'écrire :

$$\begin{aligned} m_1 &= \text{Vect}(u) + \text{Vect}(u)^\perp \\ m_1 &= \alpha_1 u + \text{Vect}(u)^\perp \end{aligned}$$

On a donc noté α_1 la coordonnée du projeté de m_1 sur u . On a :

$$\begin{aligned} \langle m_1, u \rangle &= \langle \alpha_1 u + \text{Vect}(u)^\perp, u \rangle \\ \langle m_1, u \rangle &= \langle \alpha_1 u, u \rangle \\ \langle m_1, u \rangle &= \alpha_1 \langle u, u \rangle \end{aligned}$$

$$\langle m_1, u \rangle = \alpha_1 \|u\|^2 \cos(0) = \alpha_1$$

On retrouve donc bien α_1 la coordonnée du projeté de m_1 sur u dans la "base" u . Or $M \cdot u$ n'est rien d'autre que le produit scalaire des individus m_i avec u .

Inertie/Variance du projeté

Soit X un nuage de points centré en colonne de n individus et p variables (X_1, \dots, X_p) . La matrice de covariance des (X_1, \dots, X_p) s'écrit :

$$Cov(X) = \frac{1}{n} X^T \cdot X$$

En partant de (1), la variance empirique de $\pi_u(M)$ s'écrit (on écrira Var car $\pi_u(M) \in \mathbb{R}^n$ et donc sa matrice de covariance n'est autre chose qu'un réel) :

$$Var(\pi_u(M)) = \frac{1}{p} u^T \cdot M^T \cdot M \cdot u$$

$$Var(\pi_u(M)) = u^T \frac{1}{p} M^T \cdot M \cdot u$$

$$Var(\pi_u(M)) = u^T \cdot cov(M) \cdot u \quad (2)$$

En vertu du théorème spectral, $C = cov(M) \in \mathcal{M}^{p \times p}$ étant une matrice carré symétrique, elle est diagonalisable dans une base de vecteurs propre orthonormée qu'on notera $v := (v_1, \dots, v_p)$. Notons P la matrice de changement de base constituée des vecteurs propres v_i et $\Delta = Diag(\lambda_1, \dots, \lambda_p)$ la matrice diagonale associée. On a donc :

$$C = cov(M) = P \Delta P^{-1} \quad (3)$$

Considérons que $\Delta = Diag(\lambda_1, \dots, \lambda_p)$ ait les valeurs de sa diagonale rangées en ordre décroissant. Alors le vecteur u qui maximise $Var(\pi_u(M))$ est v_1 le vecteur propre de $C = cov(M)$ associé à la première valeur propre λ_1 de Δ (c'est-à-dire la plus grande).

Preuve : Le but est de montrer que v_1 maximise (2). u peut s'écrire comme une combinaison linéaire des vecteurs propres v_i de $C = cov(M)$ qui forment une base orthonormée de \mathbb{R}^n . On peut donc écrire :

$$u = \alpha_1 v_1 + \dots + \alpha_p v_p$$

On a :

$$Cu = C(\alpha_1 v_1 + \dots + \alpha_p v_p)$$

$$Cu = \alpha_1 C v_1 + \dots + \alpha_p C v_p$$

Les v_i étant les vecteurs propres de C associés aux valeurs propres λ_i on a par définition :

$$Cu = \alpha_1 \lambda_1 v_1 + \dots + \alpha_p \lambda_p v_p$$

Pour continuer le développement de (2) on peut donc écrire :

$$u^T Cu = (\alpha_1 v_1 + \dots + \alpha_p v_p)^T \cdot (\alpha_1 \lambda_1 v_1 + \dots + \alpha_p \lambda_p v_p)$$

$$u^T Cu = (\alpha_1 v_1^T + \dots + \alpha_p v_p^T) \cdot (\alpha_1 \lambda_1 v_1 + \dots + \alpha_p \lambda_p v_p)$$

$$u^T Cu = \sum_{i=1}^p \alpha_i^2 \lambda_i v_i^T \cdot v_i + \sum_{i \neq j} \alpha_i \alpha_j \lambda_j v_i^T \cdot v_j \quad (4)$$

Les vecteurs v_i formant une base orthonormée on a $v_i^T \cdot v_i = 1$ et pour $i \neq j$, $v_i^T \cdot v_j = 0$. (4) se ramène donc à :

$$u^T Cu = \sum_{i=1}^p \alpha_i^2 \lambda_i \quad (5)$$

De plus, comme $u = \alpha_1 v_1 + \dots + \alpha_p v_p$, d'après pythagore (les vecteurs v_i formant une base orthonormée) on a :

$$\|\alpha_1 v_1\|^2 + \dots + \|\alpha_p v_p\|^2 = \|\alpha_1 v_1 + \dots + \alpha_p v_p\|^2$$

$$\alpha_1^2 + \dots + \alpha_p^2 = \|u\|^2$$

$$\alpha_1^2 + \dots + \alpha_p^2 = 1$$

Et ainsi en repartant de (5) :

$$u^T Cu = \sum_{i=1}^p \alpha_i^2 \lambda_i \leq \sum_{i=1}^p \alpha_i^2 \max(\lambda_i)$$

$$u^T Cu \leq \lambda_1 \sum_{i=1}^p \alpha_i^2$$

$$u^T Cu \leq \lambda_1$$

Donc $u^T C u$ est bornée par λ_1 et cette valeur est atteinte pour $\alpha_1 = 1, \alpha_2 = \dots = \alpha_p = 0$, c'est à dire $u = v_1$. CQFD. La valeur λ_1 est donc la variance empirique sur le premier axe de l'ACP.

De la même façon, on continue la recherche du deuxième axe de projection w sur le même principe en imposant qu'il soit orthogonal à u . On aboutit de la même façon à l'axe v_2 avec pour variance empirique λ_2 , etc. Ainsi la variance expliquée par le k -ième vecteur propre vaut λ_k .

A noter que si $n < p$, les n individus peuvent être résumés dans une base de n vecteurs maximum, il n'existera pas plus de n axes principaux. (la matrice $cov(M)$ aura des valeurs nulles dans sa diagonale. Par ex si $n = 1$, toutes ses valeurs propres sont nulles car la matrice est nulle (M est nulle par centrage des colonnes)).

Finalement, la question de l'ACP se ramène à un problème de diagonalisation de la matrice de covariance du nuage de point transformé (centré ou centré-réduit).

Algo:

Input :

- $X \in \mathcal{M}^{n \times p}$ matrice des observations avec n individus et p variables.
- k le nombre de composante principales qu'on souhaite calculer
- critère de transformation de X : "centré" ou "centré-réduit"

1 - On calcul $X_c = X - \bar{X}$ ou $X_{CR} = D_{1/\sigma}(X - \bar{X})$ avec D la matrice diagonale des inverses des écarts-types.

2 - On calcul la matrice de covariance (ou corrélation si X a été centré réduit) :

$M = 1/p (X_c^T X_c)$ ou $M = 1/p (X_{CR}^T X_{CR})$ selon le critère de transformation choisi.

3 - On diagonalise M (par exemple avec le package `simpy`), i.e on détermine la matrice orthonormée des vecteurs propre P associé à Δ avec les valeurs propres ordonnées dans l'ordre décroissant.

4 - On conserve les k premiers vecteurs propres associés à Δ , qu'on notera en matrice colonne P_k . On les appelle les axes principaux de l'ACP.

5 - Le nuage X projeté et écrit en coordonnées dans la base des k premiers vecteurs propres est : $\pi(X)_{P_k} = X \cdot P_k$

6 - On pourra calculer la matrice des corrélations entre les k nouveaux axes propres et les anciennes variables (X_1, \dots, X_p) du nuage X pour voir quelle variable "contribue" à quel axe plus ou moins.

7 - On pourra aussi calculer le pourcentage d'inertie expliqué de chaque axe propre par

$$\lambda_j / \sum_{i=1}^p \lambda_i \text{ ainsi que le pourcentage de "conservation" du nouveau nuage } \pi(X)_{P_k} \text{ par}$$

$$\sum_{i=1}^k \lambda_i / \sum_{i=1}^p \lambda_i$$

Résumé :

Les axes de projection de l'ACP sont les vecteurs propres de la matrice de covariance du nuage de point transformé (centré ou centré-réduit), notée $cov(M)$, associé aux valeurs propres dans l'ordre décroissant. (Le premier axe de projection est le vecteur propre associé à la plus grande valeur propre, qui vaut par ailleurs l'inertie du nuage projeté sur cet axe). On a aussi vu que les nouvelles coordonnées du nuage sur un de ces axes (et dans cette nouvelle base) était :

$$\pi_{v_i}(M) = M \cdot v_i$$

Donc en notant P_k la matrice constituée en colonne de nos k premiers axes propres, on a comme nouvelles coordonnées des individus dans la base de ces axes :

$$\pi(M) = MP_k \text{ avec } MP_k \in \mathcal{M}^{n \times k}.$$

P étant une matrice de passage dans la base des axes propres orthonormés, on sait que les propriétés de changement de base nous disent que :

Soit x' exprimé dans la nouvelle base exprimé par P et x exprimé dans la base canonique, alors on a :

$$\begin{aligned} Px' &= x \\ x'^T P^T &= x^T \\ x'^T P^{-1} &= x^T \\ x'^T &= x^T P \end{aligned}$$

Or MP n'est autre que cela. On aurait aussi pu dire que cela découle de l'extension de la démo de (1).

Représentation et interprétation:

On représentera couramment les individus projetés sur les axes propres 1, 2 et 3, cad en notant le nuage des individus écrit dans sa nouvelle base des axes propres :

$$X_{pca} = MP = (F_1, F_2, \dots)$$

Avec F_i la i -ème composante principale. On représentera généralement (F_1, F_2) ainsi que (F_1, F_3) dans deux plans séparés.

Pour ce qui est de l'interprétation, on aimerait ensuite dire quelles variables participent aux composantes principales. Par exemple, pour la première composante principale, on a en développant $F_1 = MP_1$ et en notant $P_1 = u_1 = (u_{1,1}, \dots, u_{1,p})$:

$$F_1 = u_{1,1}M_1 + \dots + u_{1,p}M_p$$

M étant notre nuage de point initial X centré ou centré-réduit, cela nous permet de voir quelles variables interviennent dans nos composantes principales. On peut représenter ces coordonnées dans un cercle de rayon 1 (puisque les coordonnées de u_1 sont comprises entre 0 et 1. Cette représentation est souvent noté **factor map** en anglais.

On pourra également représenter le **cercle des corrélation** entre les variables d'origine et les composantes principales.

Lien entre les axes propres et les corrélation des composantes principales avec les variables d'origine :

On notera \bar{X} la matrice X centrée et \hat{X} la matrice centrée-réduite.

En notant D_{1/σ_x} la matrice diagonale avec pour valeur en diagonale $(1/\sigma_{X_1}, \dots, 1/\sigma_{X_p})$ les inverses des écarts type des colonnes (X_1, \dots, X_p) , on a :

$$\hat{X} = \bar{X} D_{1/\sigma_x}$$

Cas 1 où le nuage M est centré-réduit, i.e $M = \hat{X}$:

On a :

$$\begin{aligned} \text{corr}(F, X) &= 1/n \hat{F}^T \hat{X} \\ \text{corr}(F, X) &= 1/n (\bar{F} D_{1/\sigma_F})^T \hat{X} \end{aligned} \quad (5)$$

Prop. $\bar{F} = F$ car $F = MP$ et M est centrée. cela se vérifie en calculant le centre de gravité de F qu'on écrit $g = F^T D_{1/n} I$, I étant le vecteur unitaire dans R^n .

On a $g = P^T M^T D_{1/n} I$, or comme M est centrée on a $M^T D_{1/n} I = 0$ et donc $g = 0$. En repartant de (5) on a donc :

$$\begin{aligned} corr(F, X) &= 1/n (F D_{1/\sigma_F})^T \hat{X} \\ corr(F, X) &= 1/n (M P D_{1/\sigma_F})^T \hat{X} \\ corr(F, X) &= 1/n D_{1/\sigma_F} P^T \hat{X}^T \hat{X} \\ corr(F, X) &= D_{1/\sigma_F} P^T \hat{X}^T 1/n \hat{X} \\ corr(F, X) &= D_{1/\sigma_F} P^T cov(M) \end{aligned}$$

Or on rappelle (voir (3)) que $cov(M) = P \Delta P^{-1}$. On a donc :

$$\begin{aligned} corr(F, X) &= D_{1/\sigma_F} P^T P \Delta P^{-1} \\ corr(F, X) &= D_{1/\sigma_F} \Delta P^{-1} \end{aligned}$$

Or on rappelle que $\Delta = diag(\lambda_1, ..., \lambda_p)$ avec $\lambda_i = Var(\pi_{u_i}(M)) = Var(MP_i) = Var(F_i) = \sigma_i^2$.

Ainsi, $\Delta = diag(\sigma_1^2, ..., \sigma_p^2) = D_{\sigma_F^2}$, et donc :

$$\begin{aligned} corr(F, X) &= D_{1/\sigma_F} D_{\sigma_F^2} P^{-1} \\ corr(F, X) &= D_{\sigma_F} P^{-1} \end{aligned}$$

Ainsi,

$$corr(F_i, X_j) = \sigma_{F_i} u_{j,i} \text{ avec } P = mat(u_{i,j})$$

Dans le cas 2 où le nuage M est centré, i.e $M = \bar{X}$:

On trouve de la même façon :

$$corr(F, X) = D_{\sigma_F} P^{-1} D_{1/\sigma_X}$$

et donc

$$corr(F_i, X_j) = \sigma_{F_i} u_{j,i} 1/\sigma_{X_j}$$